

涂喆宸

求职意向：AI 应用开发工程师 / Agent 开发工程师

21 岁 ● 手机 13862644515 ● 邮箱 ztu29@wisc.edu ● 微信 Jelly_Tu ● GitHub:https://github.com/tuzhechen2005



教育背景



威斯康星大学麦迪逊分校（UW-Madison）

UW School of Computer, Data & Information Sciences | GPA 3.7/4.0 · U.S. News 2026 全美综合 #36 / 公立大学 #12

2023.09 – 2027.05

主修计算机科学，聚焦 LLM 应用、Agent 系统、RAG 与数据基础设施；相关课程：数据结构与算法、数据库系统、操作系统、计算机网络。

荣誉 / 在校：Dean's List 校长荣誉学生名单（2023 – 2025）；Union South 运营助理（2025.01 – 至今），高峰期日均处理 300+ 单点单 / 结算 / 异常协调。

实习经历

Microsoft 微软 · 云计算与人工智能事业部

AI 应用开发工程师（实习）

2026.07 – 2026.09

工具调用评测：面向 Azure 云资源管理场景搭建本地 Phi-3 工具调用评测体系，构建 24 个 Azure REST API 工具及 320 条中英文测试指令，确立覆盖 JSON 合法率、工具路由、参数提取、Schema 合法率、字段 F1 与 Exact Match 的 6 维评测矩阵；针对小模型 Tool Calling 的参数幻觉与多工具混淆，引入 Outlines 引导式解码结构化约束，结合少样本思维链与负样本对齐治理参数偏移，并做提示词、工具规模及参数长度消融，将完整调用准确率由 61% 提升至 87%，平均推理延迟降低 28%。

文档 ReAct 智能体：基于 Semantic Kernel + Phi-3 开发本地 Azure 技术文档 ReAct 智能体，实现"自主检索-文档读取-证据回答"的工具调用闭环；设计显式状态机、动作参数校验、引用溯源、重复调用拦截及有限纠错机制，在 120 条评测问题上取得 85% 答案准确率与 92% 有效引用率，非法模型输出恢复率提升至 95%。

多智能体架构设计：基于 AutoGen + Phi-3 构建多智能体 Azure 架构设计应用，设计 Planner、Reviewer 两类智能体及"规划-审查-修订-再审"的有限轮次协作流程；使用 Pydantic 数据契约与 12 项状态转换规则校验资源清单、依赖关系和审查意见落实情况，结构化输出成功率提升至 96%，单次架构方案生成耗时控制在 60 秒以内。

事件响应智能体：基于 LLM + FastAPI + SQLite 设计并实现 Azure 事件响应智能体，打通微软公共状态源采集、RSS/Atom 安全解析、事件规范化、内容指纹去重、大模型研判、持久化存储、REST API 与中文监控面板；通过模型 API 生成事件严重级别、置信度、影响范围及六部分响应预案，在 200 条事件评测中实现 98% 结构化输出有效率与 91% 研判准确率。

可靠性与质量保障：为真实模型调用建立 JSON Schema + Pydantic 双重校验与事件 ID 一致性验证，实现超时、限流、鉴权与非法输出的错误映射、有限重试及安全降级，异常请求恢复率达 97%，并基于稳定事件 ID 与内容指纹跳过未变化事件，重复模型调用量降低 72%；建立覆盖模型适配器、Agent 状态机、采集、数据库与 API 的自动化质量体系，累计 329 项 Python 与 5 项 Node.js 测试通过率 100%，配合日志敏感与密钥环境隔离防止凭据及不可信内容进入日志。

蓝船科技有限公司 · AI 研发部

AI 应用与工作流开发工程师（实习）

2025.05 – 2025.09

跨平台 AI 工作流：基于 n8n / Coze 异构工作流引擎，设计"事件触发-多源异构数据清洗-LLM 结构化抽取-结果回写"的 DAG 自动化流水线；引入 Outlines 引导式解码结合 JSON Schema 严格数据契约与提示词模板版本化管理，配合两阶段实体对齐校验，将核心字段抽取准确率提升至 95.5%；累计上线 12 条高频业务工作流、覆盖 5 类业务场景，日均自动处理 2,000+ 条核心数据，单条端到端处理时长由约 15 分钟缩短至 2.5 分钟以内。

企业协同集成：通过 Webhook + REST API 将 AI Agent 接入 Slack / Notion，构建消息触发、任务流转与结果回传闭环；实现 HMAC 签名校验、幂等键去重、指数退避重试、死信队列与超时告警，重复执行率降至 0.5% 以下，链路成功率由 92% 提升至 99.5%，异常平均响应时间缩短至 5 分钟内。

组件沉淀：将 20+ 个通用流程节点、提示词模板与异常处理分支封装为可复用组件库，制定命名、参数与错误码规范并配套回归用例，新业务场景接入周期由约 3 天缩短至 0.5 天，团队组件复用率 80%+。

江苏力群科技有限公司 · 数据中台事业部

数据中台开发实习生

2025.09 – 2025.12

实时数据管道：基于 Apache Flink + Kafka 构建 Exactly-Once 语义的实时清洗与 ETL 链路，接入 8 个业务数据源、日均处理 500 万+ 条记录；通过 Watermark 处理乱序事件、Side Output 分流脏数据、广播规则表实现字段标准化，配套 Checkpoint、任务状态监控与失败告警，端到端延迟 <5 秒，脏数据拦截率 99%+，任务可用性 99.9%。

Text-to-SQL 问答：面向 200+ 张表的复杂 Schema 设计 Schema-aware 检索（表 / 字段向量召回 + 外键图扩展）与字段裁剪策略，结合 Few-shot 示例检索与 SQL 执行错误自纠错重试，输入上下文压缩 60%+；在 300 条业务问题评测集上 SQL 执行准确率由 62% 提升至 85%，取数由小时级降至分钟级，业务数据获取效率提升约 300%。

安全管控与落地：结合只读账号、SQL AST 白名单、参数化校验、查询超时与结果行数限制构建多层防护，危险语句拦截率 100%；推动系统在公司内部正式落地，覆盖 6 个业务部门、月均 1,500+ 次查询。

项目经历

企业级 RAG AI 智能助手

2025.05 – 2025.09

统一接入结构化数据库与非结构化文档的 RAG 问答系统，自然语言驱动数据查询与知识检索。

检索与路由：采用 Query Rewrite / Decompose 与 HyDE 扩展高维意图，结合 BM25 稀疏检索与 Qwen3-Embedding-4B 稠密向量检索多路召回，经 RRF 融合降维后接入 DistilBERT 微调的轻量意图分类器（边界置信度阈值 + 复杂 Case 的 LLM 兜底），文档 / SQL / 混合三路路由准确率 93%；针对 Cross-Encoder 重排的高计算开销引入 Cascade Rerank（Bi-Encoder 粗筛 Top-50 → Qwen3-Reranker-4B 精排 Top-10），在 500 条自建评测集上复杂查询 Recall@10 提升 18%、Top-5 相关性提升 20%，端到端检索耗时控制在 120ms 以内。

上下文与权限：按模型上下文长度设置 Token Budget，采用 Parent-Child / Small-to-Big 检索（子块精准召回、父块补全上下文）、MMR 去冗余与动态 Top-K，超限优先保留高相关片段与来源映射，平均上下文 Token 减少 35% 而答案质量持平；使用 JWT + RBAC 在检索前执行文档 ACL 元数据过滤，权限测试中越权访问 0 例。

Text-to-SQL 强校验：使用只读连接、Schema 白名单、SQL AST 校验、查询超时与结果集上限，在 200 条对抗样本中危险语句拦截率 100%，SQL 执行准确率 84%。

并发与评测：使用 Milvus（HNSW 索引）向量库、Redis 热点缓存与 single-flight 合并回源，配合 asyncio 异步检索、连接池与超时重试降级，200 并发下 P95 延迟降低 30%+、缓存命中率 70%+；建立 Ragas 式评测（可溯源率、事实一致性、拒答正确率、延迟），通过 Retrieval Feedback + Self-Reflection 使事实一致性提升 15%+、高风险场景幻觉率下降 20%+，回答可溯源率 92%。

多智能体医疗预问诊与导诊系统

2026.01 – 至今

面向常见科室的医疗预问诊与导诊系统，多 Agent 协作完成结构化采集与分诊，定位决策支持、不做诊断与处方。

多 Agent 编排：基于 LangGraph 构建协调、问诊采集、知识检索、分诊导诊与安全护栏 5 类 Agent，创新采用"集中式 Supervisor + 局部 ReAct 子图"分层状态机架构，以有关状态图 + 条件边保障长链路调度确定性，引入动态状态剪枝与 Checkpoint 增量持久化；结合 Plan-and-Execute 动态追问与结构化槽位填充，在覆盖 12 个常见科室的测试中，关键信息采集完整度由约 70% 提升至 92%，平均问诊轮次由 12 轮压缩至 6.5 轮，多轮交互 Token 消耗降低 28%。

可控工具调用：将 RAG 封装为 Function Calling 工具，使用 JSON Schema + Pydantic 约束输入输出并校验必填字段、枚举值与调用权限；接入 300+ 篇临床指南分块索引与元数据过滤，回答可溯源率 90%+、工具调用准确率 95%+。

安全护栏与可观测性：在生成前后执行急症红旗"规则 + LLM"双重识别、越界拒答、事实一致性复核与 HITL 人工升级，在约 180 条评测集中急症召回率 96%+、分诊 Top-2 命中率 88%+、越界拒答正确率 97%；通过 LangSmith / Langfuse 追踪 Trace、耗时与失败节点，配合轮次 / Token 上限与异常回退，失败会话率 <2%，单轮响应 P95 <4 秒。

AI 辅助研发

- 模型使用与选型：深度使用 GPT-5.6、Claude Fable 5.1 / Opus 5 / Sonnet 5、Gemini 3、DeepSeek V4、Qwen 3.5、Llama、Phi 等主流闭源与开源模型，熟悉各家 API 在 Function Calling、JSON Mode、流式输出、Prompt Caching 上的差异，能按质量 / 成本 / 延迟做混合调度；本地通过 Ollama / vLLM 部署量化模型并做离线评测。
- 编码 Agent 与 Harness：日常使用 Claude Code、Codex CLI、Cursor、GitHub Copilot 完成需求拆解、代码生成、重构与测试补全，以 CLAUDE.md / .cursorrules 沉淀项目规范、通过 MCP 接入自定义工具与 Skill，并用 Subagent 并行处理独立模块；上述 329 项测试即以 AI 结对方式完成，个人研发效率提升约 2 倍。
- 提示词与评测方法：熟练 System Prompt 设计、Few-shot、CoT、结构化输出约束与提示词版本管理，坚持以评测集 + A/B 对比而非主观感受判断提示词与模型改动效果。

专业技能

AI / Agent: LangGraph、Semantic Kernel、AutoGen、ReAct、Plan-and-Execute、Function Calling、Outlines 引导式解码、Prompt Engineering、LangSmith、Langfuse
RAG / 检索: GraphRAG、Parent-Child / Small-to-Big Retrieval、Milvus、BM25、Dense Retrieval（Qwen3-Embedding）、Cross-Encoder / Cascade Rerank（Qwen3-Reranker）、RRF、Elasticsearch、Ragas
推理部署 / 微调: vLLM、SGLang、Ollama、LoRA / QLoRA、SFT、模型量化与本地化部署
数据 / 后端: Apache Flink、Kafka、Text-to-SQL、Spring、FastAPI、Pydantic、Redis、JWT / RBAC、Webhook、n8n / Coze、Streamlit
编程语言: Java、Python、SQL